Analisi per la predizione del prezzo di un auto usata

Programmazione di Applicazioni Data Intensive
Laurea in Ingegneria e Scienze Informatiche
DISI - Università di Bologna, Cesena

Ciandrini Davide e Giorgetti Alex
`davide.ciandrini@studio.unibo.it`
`alex.giorgetti@studio.unibo.it`

Parte 1 - Descrizione del problema e comprensione dei dati

Come obiettivo ci siamo posti quello di realizzare un modello che predica il prezzo di auto usate.
Abbiamo deciso di utilizzare un dataset presente su Kaggle al seguente indirizzo.
Questo dataset è stato ricavato dal sito web cardekho sulla base di informazioni del 2020.

Caricamento librerie

- Andiamo a caricare tutte le librerie necessarie per lo svolgimento del progetto

In [ ]:
```
%matplotlib inline
import os.path
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import plotly.graph_objects as go
from plotly.subplots import make_subplots
import seaborn as sb
```

- Questo ci permette di nascondere tutti i warning presenti durante l'esecuzione del codice.

In [ ]:
```
import warnings
from sklearn.exceptions import ConvergenceWarning
warnings.filterwarnings("ignore", category=ConvergenceWarning)
```

Caricamento dei dati

In [ ]:
```
file_csv_url = "https://raw.githubusercontent.com/alexgiorgetti/vehicle-dataset-from-cardekho/main/cars.csv"
file_name    = "cars.csv"

if not os.path.exists(file_name):
    from urllib.request import urlretrieve
    urlretrieve(file_csv_url, file_name)
```

In [ ]:
```
data = pd.read_csv(file_name, sep = ",")
```

In [ ]:
```
data.head(5)
```

Out[ ]:

	Car_Name	Year	Selling_Price	Present_Price	Kms_Driven	Fuel_Type	Seller_Type	Transmission	Owner
0	ritz	2014	3.35	5.59	27000	Petrol	Dealer	Manual	0
1	sx4	2013	4.75	9.54	43000	Diesel	Dealer	Manual	0
2	ciaz	2017	7.25	9.85	6900	Petrol	Dealer	Manual	0
3	wagon r	2011	2.85	4.15	5200	Petrol	Dealer	Manual	0
4	swift	2014	4.60	6.87	42450	Diesel	Dealer	Manual	0

- Analizziamo le dimensioni in memoria, la tipologia delle feature assegnate da pandas e le istanze non nulle.

In [ ]:
```
data.info(memory_usage = "deep")
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 301 entries, 0 to 300
Data columns (total 9 columns):
 #   Column         Non-Null Count  Dtype
---  ------         --------------  -----
 0   Car_Name       301 non-null    object
 1   Year           301 non-null    int64
 2   Selling_Price  301 non-null    float64
 3   Present_Price  301 non-null    float64
 4   Kms_Driven     301 non-null    int64
 5   Fuel_Type      301 non-null    object
 6   Seller_Type    301 non-null    object
 7   Transmission   301 non-null    object
 8   Owner          301 non-null    int64
dtypes: float64(2), int64(3), object(4)
memory usage: 87.6 KB
```

- Come possiamo vedere `Fuel_Type`, `Seller_type` e `Trasmission` sono considerate come stringhe, ma sapendo che sono categoriche possiamo cambiare la tipologie e ricaricare il DataFrame.

In [ ]:
```
new_dtypes = {
    "Fuel_Type": "category",
    "Seller_Type": "category",
    "Transmission": "category"
}
data = pd.read_csv("cars.csv", dtype = new_dtypes)
```

- Possiamo vedere subito come l'occupazione in memoria è stata ridotta di oltre 50KB
  Questa scelta per Dataset come questi, non è rilevante, ma per altre molto più grandi può incidere particolarmente.

In [ ]:
```
data.info(memory_usage = "deep")
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 301 entries, 0 to 300
Data columns (total 9 columns):
 #   Column         Non-Null Count  Dtype
---  ------         --------------  -----
 0   Car_Name       301 non-null    object
 1   Year           301 non-null    int64
 2   Selling_Price  301 non-null    float64
 3   Present_Price  301 non-null    float64
 4   Kms_Driven     301 non-null    int64
 5   Fuel_Type      301 non-null    category
 6   Seller_Type    301 non-null    category
 7   Transmission   301 non-null    category
 8   Owner          301 non-null    int64
dtypes: category(3), float64(2), int64(3), object(1)
memory usage: 33.0 KB
```

- Impostando a `Category` possiamo vedere subito quali sono le possibili scelte, come nel caso del `Fuel_Type`:

In [ ]:
```
data["Fuel_Type"].head(5)
```

Out[ ]:
```
0    Petrol
1    Diesel
2    Petrol
3    Petrol
4    Diesel
Name: Fuel_Type, dtype: category
Categories (3, object): ['CNG', 'Diesel', 'Petrol']
```

Significato delle feature

- `Car_name` : Nome dell'auto
- `Year` : Anno di produzione
- `Selling_Price` : Prezzo richiesto dal venditore
- `Present_Price` : Prezzo di listino
- `Kms_Driven` : Km percorsi dall'auto
- `Fuel_Type` : Tipologia di carburante
- `Seller_Type` : Tipologia di venditore
- `Transmission` : Tipologia di cambio
- `Owner` : Numero di possessori

Le tipologie di dati presenti sono:

- Numeri interi per l'anno, il kilometraggio e possessore
- Numeri non interi per il prezzo
- String per il nome
- Categorici i restanti

Analisi delle singole feature

In [ ]:
```
data.describe(include = "all")
```

Out[ ]:

	Car_Name	Year	Selling_Price	Present_Price	Kms_Driven	Fuel_Type	Seller_Type	Transmission	Owner
count	301	301.000000	301.000000	301.000000	301.000000	301	301	301	301.000000
unique	98	NaN	NaN	NaN	NaN	3	2	2	NaN
top	city	NaN	NaN	NaN	NaN	Petrol	Dealer	Manual	NaN
freq	26	NaN	NaN	NaN	NaN	239	195	261	NaN
mean	NaN	2013.627907	4.661296	7.628472	36947.205980	NaN	NaN	NaN	0.043189
std	NaN	2.891554	5.082812	8.644115	38886.883882	NaN	NaN	NaN	0.247915
min	NaN	2003.000000	0.100000	0.320000	500.000000	NaN	NaN	NaN	0.000000
25%	NaN	2012.000000	0.900000	1.200000	15000.000000	NaN	NaN	NaN	0.000000
50%	NaN	2014.000000	3.600000	6.400000	32000.000000	NaN	NaN	NaN	0.000000
75%	NaN	2016.000000	6.000000	9.900000	48767.000000	NaN	NaN	NaN	0.000000
max	NaN	2018.000000	35.000000	92.600000	500000.000000	NaN	NaN	NaN	3.000000

- Grazie al metodo describe riusciamo a ottenere varie statistiche che ci possono aiutare ad analizzare il nostro Dataset.
- Come prima cosa possiamo vedere come l'Owner è tendente allo 0, questo ci fa capire come la maggior parte delle macchine ha avuto un solo proprietario.
- A seguire analizziamo la differenza tra Selling e Present medio, vedendo come si distacchi la media di circa 3.0. Nonostante si abbia un prezzo medio relativamente basso abbiamo picchi di massimo molto più alti, fino a 35.0
- Vediamo inoltre come quasi l'80% delle auto ha come carburante il Petrolio e come cambio quello Manuale.
- Infine è bene notare che oltre il 60% delle automobili venga venduta da concessionari.

In [ ]:
```
def numerical_graph():
  fig = make_subplots(rows = 2, cols = 2, subplot_titles = ("Selling Price", "Present Price", "KMs", "Year"))

  fig.add_trace(go.Histogram(x = data["Selling_Price"], name = "Selling Cost"), row = 1, col = 1)
  fig.add_trace(go.Histogram(x = data["Present_Price"], name = "Present Cost"), row = 1, col = 2)
  fig.add_trace(go.Histogram(x = data["Kms_Driven"], name = "Kms"), row = 2, col = 1)
  fig.add_trace(go.Histogram(x = data["Year"], name = "Days"), row = 2, col = 2)
  fig.show()
```

- Qui di seguito sono riportati 4 istogrammi che analizzano la densità di frequenza, rispettivamente di `Selling Price`, `Present Price`, `KMs` e `Years`.

In [ ]:
```
numerical_graph()
```

- Si può notare che le prime tre le distribuzioni decrescono con l'aumentare dei valori, mentre per l'anno possiamo notare che più aumenta e più macchine risultano vendute.
  Questo ci fa capire che c'è una prevalenza di mercato sulle macchine nuove rispetto a macchine di parecchi anni fa.

In [ ]:
```
def category_graph():
  fig = make_subplots(rows = 2, cols = 2, subplot_titles = ("Fuel Type", "Seller Type", "Transmission", "Owner"

  fig.add_trace(go.Histogram(x = data["Fuel_Type"], name = "Fuel"), row = 1, col = 1)
  fig.add_trace(go.Histogram(x = data["Seller_Type"], name = "Seller"), row = 1, col = 2)
  fig.add_trace(go.Histogram(x = data["Transmission"], name = "Transmission"), row = 2, col = 1)
  fig.add_trace(go.Histogram(x = data["Owner"], name = "Owner"), row = 2, col = 2)
  fig.show()
```

- Qui di seguito invece sono riportati 4 istogrammi che analizzano la densità di frequenza, rispettivamente di `Fuel Type`, `Seller Type`, `Transmission` e `Owner`.

In [ ]:
```
category_graph()
```

- Per la tipologia di carburante abbiamo solo 2 casi di CNG e dunque possiamo eliminare quelle due auto dal DataFrame dato che l'incidenza non sarebbe rilevante.
- Gran parte delle auto si avvicinano sia per Venditore che Cambio
- L'Owner essendo praticamente sempre sullo 0 anche in questo caso, ci fa pensare che non potrà incidere particolarmente sulla predizione del Selling Price.

Rimuoviamo quindi le auto con carburante CNG.

In [ ]:
```
data = data[data['Fuel_Type'] != "CNG"]
```

Esplorazione e analisi delle correlazioni tra feature

A questo punto vediamo i grafici di dispersione di Selling Price e Present Price sulla base delle feature categoriche, in questo caso la tipologia di cambio (Manuale o Automatico), la tipologia di carburante (Diesel o Petrol) e la tipologia di venditore (Privato o Concessionaria).

In [ ]:
```
def create_plot(first, second, value):
  time_colors = {first: "red", second: "blue"}
  p = data.plot.scatter("Present_Price",
                        "Selling_Price",
                        c = data[value].map(time_colors));
  return p
```

In [ ]:
```
create_plot("Manual", "Automatic", "Transmission")
```

Out[ ]: `<matplotlib.axes._subplots.AxesSubplot at 0x7f8b0c0ce8d0>`

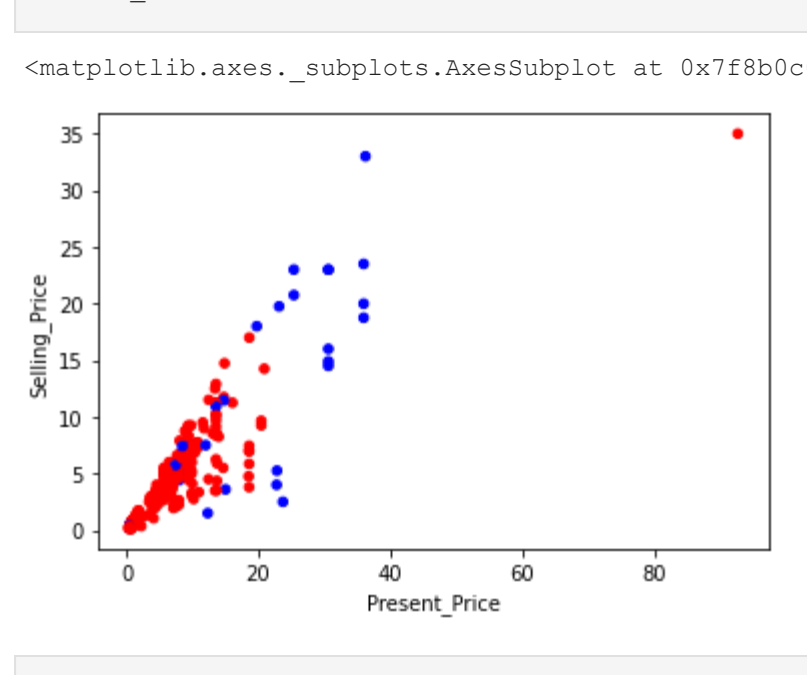

In [ ]:
```
create_plot("Diesel", "Petrol", "Fuel_Type")
```

Out[ ]: `<matplotlib.axes._subplots.AxesSubplot at 0x7f8b0bfd60d0>`

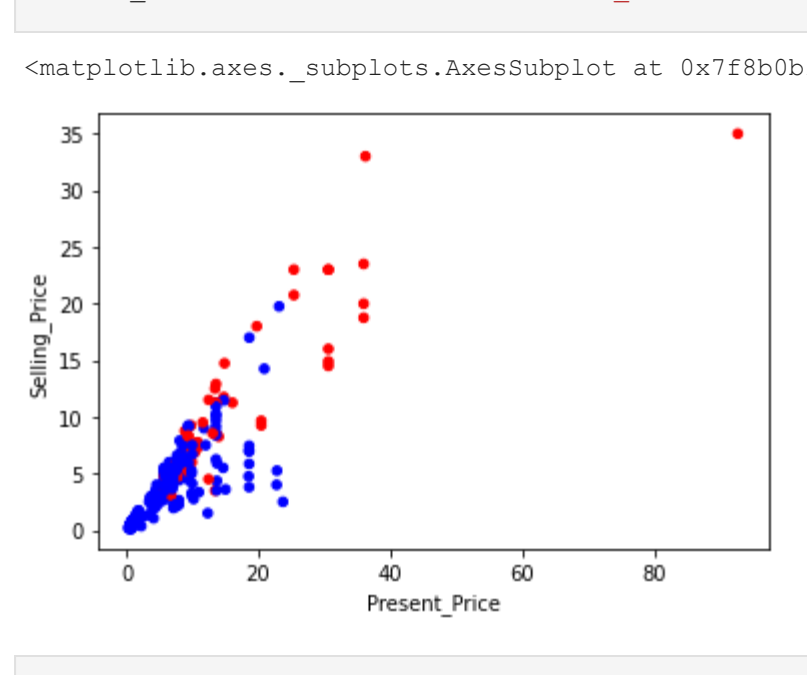

In [ ]:
```
create_plot("Individual", "Dealer", "Seller_Type")
```

Out[ ]: `<matplotlib.axes._subplots.AxesSubplot at 0x7f8b0bb17c10>`

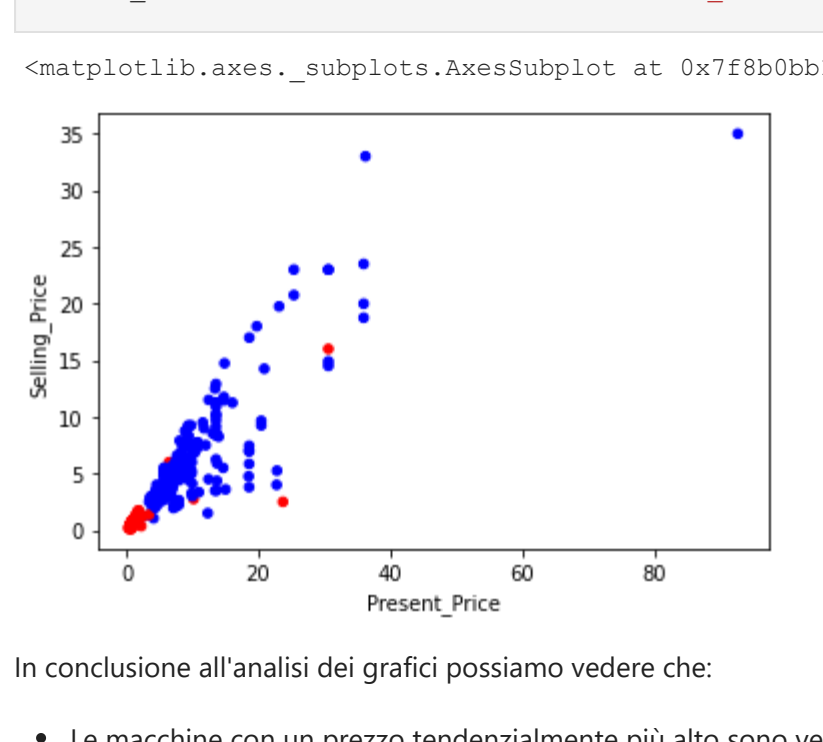

In conclusione all'analisi dei grafici possiamo vedere che:

- Le macchine con un prezzo tendenzialmente più alto sono vendute da un concessionario, hanno come carburante il Diesel e come cambio Automatico.
- Le macchine con un prezzo tendenzialmente più basso sono vendute da un privato, hanno come carburante il Benzina e come cambio Manuale.

Parte 2 - Preparazione del modello

In questa fase il nostro obiettivo è quello di riorganizzare il Dataset, eliminare le parti non necessarie e poi creare Training e Validation set.
Successivamente studieremo la correlazione tra variabili.

Riorganizzazione dei dati

- Come vediamo la colonna dei nomi delle automobili non è necessaria, ma per eventuali modifiche, creiamo un vettore corrispondente agli indici del nostro Dataset, con il quale sarà poi possibile ricavare i nomi in un secondo momento.

In [ ]:
```
car_names = data["Car_Name"]
data = data.drop(columns = "Car_Name")
```

- Dato che l'anno dell'automobile non è generalizzato, modifichiamo quest'ultimo aggiungendo l'età rispettiva.

In [ ]:
```
data["Car_Age"] = 2021 - data["Year"]
data = data.drop(columns = "Year")
```

- Per convertire tutte le colonne categoriche usiamo una funzione di pandas `get_dummies` che ci permette di suddividerle in diverse colonne facilitandoci la fase di correlazione.

In [ ]:
```
data = pd.get_dummies(data, drop_first = True)
data.head()
```

Out[ ]:

	Selling_Price	Present_Price	Kms_Driven	Owner	Car_Age	Fuel_Type_Diesel	Fuel_Type_Petrol	Seller_Type_Individual	Transmission_Manual
0	3.35	5.59	27000	0	7	0	1	0	1
1	4.75	9.54	43000	0	8	1	0	0	1
2	7.25	9.85	6900	0	4	0	1	0	1
3	2.85	4.15	5200	0	10	0	1	0	1
4	4.60	6.87	42450	0	7	1	0	0	1

- Da questa tabella possiamo studiare la correlazione tra tutte le feature presenti nel nostro Dataset. Possiamo subito notare come il prezzo di Vendita che il prezzo di Listino siano i più correlati. A seguire anche la correlazione con Diesel risulta essere superiore alla media.

In [ ]:
```
data.corr()
```

Out[ ]:

	Selling_Price	Present_Price	Kms_Driven	Owner	Car_Age	Fuel_Type_Diesel	Fuel_Type_Petrol	Seller_Type_Individual
Selling_Price	1.000000	0.879131	0.029546	-0.088741	-0.236047	0.551948	-0.551948	-0.553425
Present_Price	0.879131	1.000000	0.203665	0.007895	0.047172	0.473300	-0.473300	-0.513733
Kms_Driven	0.029546	0.203665	1.000000	0.089417	0.524285	0.173191	-0.173191	-0.100885
Owner	-0.088741	0.007895	0.089417	1.000000	0.182697	-0.054102	0.054102	0.123646
Car_Age	-0.236047	0.047172	0.524285	0.182697	1.000000	-0.063754	0.063754	0.041116
Fuel_Type_Diesel	0.551948	0.473300	0.173191	-0.054102	-0.063754	1.000000	-1.000000	-0.353865
Fuel_Type_Petrol	-0.551948	-0.473300	-0.173191	0.054102	0.063754	-1.000000	1.000000	0.353865
Seller_Type_Individual	-0.553425	-0.513733	-0.100885	0.123646	0.041116	-0.353865	0.353865	1.000000
Transmission_Manual	-0.366627	-0.348576	-0.163016	-0.049889	-0.000966	-0.097468	0.097468	0.065323

Validation set

In [ ]:
```
from sklearn.linear_model import Lasso, LinearRegression, Ridge
from sklearn.model_selection import train_test_split
from sklearn.pipeline import Pipeline
from sklearn.metrics import mean_squared_error, r2_score

from sklearn.preprocessing import StandardScaler
```

- Creiamo una funziona che ci aiuterà per determinare quale modello ci aiuta maggiormente per la pedizione della nostra y

In [ ]:
```
def relative_error(y_true, y_pred):
    return np.mean(np.abs((y_true - y_pred) / y_true))

def print_eval(X, y, model):
    preds = model.predict(X)
    print("   Mean squared error: {:.5}".format(mean_squared_error(y, preds)))
    print("       Relative error: {:.5%}".format(relative_error(y, preds)))
    print("R-squared coefficient: {:.5}".format(r2_score(y, preds)))
```

* Dividiamo in due parti il nostro Dataset per gestire la parte di Validation e Training. Dato che il nostro obiettivo è stimare il `Selling_Price` andremo a creare X e y in questo modo:

- **X**: Conterrà tutte le feature eccetto la `Selling_Price`
- **y**: Conterrà solamente la colonna del `Selling_Price`

- Per fare questa operazione utilizziamo il metodo `Hold-out`. La valutazione può dipendere fortemente da quali dati finiscono nel set di addestramento e quali finiscono nel set di test, e quindi può essere significativamente diversa a seconda di come viene fatta la divisione.

In [ ]:
```
y = data["Selling_Price"]
X = data.drop(columns = "Selling_Price")
```

In [ ]:
```
X_train, X_val, y_train, y_val = train_test_split(
    X,
    y,
    test_size = 0.2, #Possiamo variare tra 0.2 e 0.3
    random_state = 42
)
```

- Qui vediamo com'è stato diviso il nostro Dataset:

In [ ]:
```
print(f"Training set:  {X_train.shape}\nValidation set:  {X_val.shape}")
```

```
Training set:  (239, 8)
Validation set:  (60, 8)
```

Creazione e analisi di modelli di Regressione

- Il nostro obiettivo è quello di creare un modello che ci permetta di stimare il prezzo di vendita di un Automobile. Studiamo e testiamo diversi modelli finchè non troviamo quello che faccia al caso nostro.
- Come primo modello iniziamo con una **Regressione Lineare** semplice:

In [ ]:
```
lrm = LinearRegression()
lrm.fit(X_train, y_train)
```

Out[ ]:
```
LinearRegression(copy_X=True, fit_intercept=True, n_jobs=None, normalize=False)
```

In [ ]:
```
print_eval(X_val, y_val, lrm)
```

```
   Mean squared error: 13.06
       Relative error: 214.08918%
R-squared coefficient: 0.63086
```

In [ ]:
```
pd.Series(lrm.coef_, index = X_train.columns)
```

Out[ ]:
```
Present_Price             0.600259
Kms_Driven               -0.000024
Owner                    -1.094918
Car_Age                  -0.267790
Fuel_Type_Diesel          0.759270
Fuel_Type_Petrol         -0.759270
Seller_Type_Individual   -0.249847
Transmission_Manual      -0.809224
dtype: float64
```

- Da qui possiamo osservare come sia il Present Price che il carburante di tipo Diesel incidano particolarmente sulla previsione dei nuovi dati. Questo tipo di andamento era già stato notato con la tabella di correllazione.
- Cerchiamo dunque di migliorare il modello utilizzando una regolarizzazione L2, chiamata **Regressione Ridge**.

In [ ]:
```
for i in [0.01, 0.1, 1.0]:
  model_b = Ridge(alpha = i)
  model_b.fit(X_train, y_train)
  print(f'Alpha {i}\n')
  print_eval(X_val, y_val, model_b)
  print('\n')
```

```
Alpha 0.01

   Mean squared error: 13.061
       Relative error: 214.10217%
R-squared coefficient: 0.63083


Alpha 0.1

   Mean squared error: 13.069
       Relative error: 214.21817%
R-squared coefficient: 0.63062


Alpha 1.0

   Mean squared error: 13.143
       Relative error: 215.29975%
R-squared coefficient: 0.62852
```

- Analizziamo con 3 differenti valori di alpha e vediamo che in tutti e tre i casi il nostro score si abbassa.

Standardizzazione

- Vedendo l'andamento dei due casi precedenti proviamo a standardizzare i nostri dati per migliorare il modello. Adottiamo un metodo di regolarizzazione L1.
- La **Regressione Lasso** è basata sulla minimizzazione della funzione d'errore.
  Come per il caso precedente, alpha, determina il peso della regolarizzazione.

In [ ]:
```
for i in [0.01, 0.1, 1.0]:
  std_lasso_model = Pipeline([
    ("scale", StandardScaler()),
    ("regr", Lasso(alpha = i))
  ])

  std_lasso_model.fit(X_train, y_train)
  print(f'Alpha {i}\n')
  print_eval(X_val, y_val, std_lasso_model)
  print('\n')
  print(pd.Series(std_lasso_model.named_steps["regr"].coef_, index = X.columns))
  print('\n')
```

```
Alpha 0.01

   Mean squared error: 12.918
       Relative error: 211.35184%
R-squared coefficient: 0.63487


Present_Price             4.057043e+00
Kms_Driven               -6.417472e-01
Owner                    -2.802935e-01
Car_Age                  -7.655447e-01
Fuel_Type_Diesel          5.796293e-01
Fuel_Type_Petrol         -1.549667e-15
Seller_Type_Individual   -1.129985e-01
Transmission_Manual      -2.635183e-01
dtype: float64


Alpha 0.1

   Mean squared error: 11.752
       Relative error: 187.90027%
R-squared coefficient: 0.66784


Present_Price             4.030387e+00
Kms_Driven               -5.150193e-01
Owner                    -2.141841e-01
Car_Age                  -7.841287e-01
Fuel_Type_Diesel          4.996070e-01
Fuel_Type_Petrol         -9.067596e-16
Seller_Type_Individual   -5.437854e-02
Transmission_Manual      -1.887520e-01
dtype: float64


Alpha 1.0

   Mean squared error: 6.3839
       Relative error: 94.10376%
R-squared coefficient: 0.81956


Present_Price             3.336929
Kms_Driven               -0.000000
Owner                    -0.000000
Car_Age                  -0.316671
Fuel_Type_Diesel          0.000000
Fuel_Type_Petrol         -0.000000
Seller_Type_Individual   -0.000000
Transmission_Manual      -0.000000
dtype: float64
```

- In questo caso invece, vediamo fin da subito come all'aumentare di Alpha riusciamo ad ottenere un coefficiente R^2 decisamente migliore, confermando la feature `Present_Price` più decisiva.

Parte 3 - Studio con Grid Search e Nested cross validation

Con la cross validation andiamo a valutare un modetto su dati diversi rispetto a come è addestrato. Lavora su due processi, uno interno per trovare gli iperparametri migliori ed uno esterno per stimare l'accuratezza media dei dati. Fin'ora abbiamo usato il metodo `hold-out`, adesso andiamo ad utilizzare il metodo di `Nested K-fold` per avere una validazione più accurata. Tramite la `Grid Search` generiamo poi N modelli differenti per stimare gli iperparametri e calcolare l'effettiva accuratezza dei modelli.

Importazioni delle librerie

In [ ]:
```
from sklearn.preprocessing import PolynomialFeatures
from sklearn.linear_model import ElasticNet
from sklearn.model_selection import KFold, cross_validate, GridSearchCV
from sklearn.kernel_ridge import KernelRidge
from sklearn.decomposition import PCA

import xgboost as xgb
import seaborn as sns
```

Definizione dello studio Nested

- Definiamo un metodo che ci aiuti con la realizzazione una di una funzione che ci permetta di eseguire la nested cross validation.
  Per ogni GS andiamo a salvarci lo score e successivamente torniamo il modello con il rispettivo score migliore.
  Ci troveremo poi un dict con tutti i modelli studiati e il loro score.

In [ ]:
```
models = {}

outer_cv = KFold(3, shuffle=True, random_state=42)
inner_cv = KFold(5, shuffle=True, random_state=42)

def nested_cv(model, grid):
    results = {}
    for train_indices, val_indices in outer_cv.split(X, y):
        X_train, y_train = X.iloc[train_indices], y.iloc[train_indices]
        X_val, y_val = X.iloc[val_indices], y.iloc[val_indices]
        gs = GridSearchCV(model, grid, cv = inner_cv, refit = True)
        gs.fit(X_train, y_train)
        score = gs.score(X_val, y_val)
        results.update({score:gs})

        print(f"Score: {format(score)}")

    final_score = max(results.keys())
    return results[final_score], final_score
```

- Adesso cerchiamo i parametri ottimi utilizzando gli stessi modelli analizzati sopra utilizzando una GridSearch

Lasso

- La regressione lasso consiste nella regressione lineare con regolarizzazione L1, basata quindi sul minimizzare la funzione d'errore. Il parametro alpha controlla il peso della regolarizzazione, andiamo infatti a studiare il modello sulla base di 4 possibili alpha.

In [ ]:
```
lasso_model = Pipeline([
    ("poly", PolynomialFeatures(include_bias = False)),
    ("std", StandardScaler()),
    ("regr", Lasso())
])

grid = {
    "poly__degree": [2, 3],
    "regr__alpha": [0.01, 0.1, 1, 10]
}

mdl, score = nested_cv(lasso_model, grid)
models["Lasso"] = {"Model": mdl, "Score": score}
```

```
Score: 0.9480423187280278
Score: 0.9357238617048166
Score: 0.8833103082596883
```

Ridge

- La regressione Ridge, a differenza della Lasso, consiste nella regressione lineare con regolarizzazione L2. In questo modo parametri molto alti in valore assoluto sono molto penalizzati. Anche per questo modello andiamo a studiare diversi alpha.

In [ ]:
```
ridge_model = Pipeline([
    ("poly",  PolynomialFeatures(include_bias=False)),
    ("scale", StandardScaler()),
    ("regr",  Ridge())
])

grid = {
    "poly__degree": [2, 3],
    "regr__alpha":  [0.1, 1, 10]
}

mdl, score = nested_cv(ridge_model, grid)
models["Ridge"] = {"Model": mdl, "Score": score}
```

```
Score: 0.8741752780202575
Score: 0.9393047174910334
Score: 0.9665859671744659
```

Elastic Net

- Dopo aver testate Ridge e Lasso in maniera seperata con questo metodo andiamo ad unire le due regressioni L2 e L1. Con alpha definiamo il peso generale mentre con l1_ratio il peso di L1 relativo al totale.

In [ ]:
```
elastic_model = Pipeline([
    ("poly", PolynomialFeatures(include_bias = False)),
    ("std", StandardScaler()),
    ("regr", ElasticNet())
])

grid = {
    "poly__degree": [2, 3],
    "regr__alpha": [0.1, 1, 10],
    "regr__l1_ratio": [0.1, 0.25, 0.5]
}

mdl, score = nested_cv(elastic_model, grid)
models["Elastic_Net"] = {"Model": mdl, "Score": score}
```

```
Score: -1.1007246158654826
Score: 0.9192083154919127
Score: 0.6461539596626545
```

XGBoost

- Questa tipologia di algoritmo ci permette di prevedere con precisione una variabili di destinazione combinando le stime di un insieme di modelli più semplici e deboli. XGBoost riduce al minimo una funzione oggettiva regolarizzata (L1 e L2) che combina una funzione di perdita convessa e un termine di penalità della complessità del modello

In [ ]:
```
xgb_model = Pipeline([
    ("Scale", StandardScaler()),
    ("PCA", PCA()),
    ("regr", xgb.XGBRegressor(objective ='reg:squarederror'))
])

grid = {
    'PCA__n_components': [5],
    'regr__n_estimators': [1000],
    'regr__max_depth': [3],
    'regr__alpha': [0.1, 1, 10],
    'regr__lambda': [0.1]
}

mdl, score = nested_cv(xgb_model, grid)
models["XGBoost"] = {"Model": mdl, "Score": score}
```

```
Score: 0.8057702821875574
Score: 0.9151423128549061
Score: 0.9139021438276191
```

Risultati

- Controlliamo i risultati migliori per tutti i modelli studiati:

In [ ]:
```
for model in models:
  print(f"{model}:\n\t\t{models[model]['Score']}")
```

```
Lasso:
                0.9480423187280278
Ridge:
                0.9665859671744659
Elastic_Net:
                0.9192083154919127
XGBoost:
                0.9151423128549061
```

Parte 4 - Valutazione dei modelli studiati

A questo punto andiamo a valutare con più attenzione i modelli che abbiamo individuato. Utilizziamo la funzione precedentemente definita `print_val` la quale ci tornerà per ogni modello addestrato i suoi:

- Errore quadratico medio
- Errore relativo